

Econometría

El modelo de regresión lineal múltiple

Alejandro Mosiño - *Universidad de Guanajuato*

v.2026.09.23

**Cuando solo un regresor no es
suficiente**

¿Qué dejamos dentro de u_i ?

En regresión lineal simple estudiamos la relación entre dos variables:

$$y_i = \beta_1 + \beta_2 x_i + u_i$$

Pero x_i no es lo único que explica por qué y_i cambia. ¿O sí?

¿Qué representa entonces u_i ?

Precio, ventas... ¿y nada más?

Supongamos que queremos estudiar la asociación entre el *precio* de un producto y sus *ventas*:

$$ventas_i = \beta_1 + \beta_2 precio_i + u_i$$

¿Qué otros factores podrían explicar que establecimientos con precios similares tengan ventas diferentes?

¿Qué te parece el *gasto en publicidad*? Si podemos observarlo, podemos incorporarlo explícitamente al modelo, de tal forma que, ahora:

$$ventas_i = \beta_1 + \beta_2 precio_i + \beta_3 publicidad_i + u_i.$$

Entonces, ¿qué cambia?

Con regresión simple preguntábamos: ¿Cómo se asocian el precio y las ventas? Pero, ahora, al incorporar la publicidad, podemos formular una pregunta diferente:

¿Cómo se asocian el precio y las ventas *manteniendo constante la publicidad?*

Una nueva dimensión

Con una variable explicativa representábamos la relación entre x y y mediante una recta. ¡Pero ahora tenemos una dimensión adicional! En nuestro ejemplo tenemos:

WebGL is not supported by your
browser - visit <https://get.webgl.org>
for more info

El plano de regresión

Nota que ahora tenemos un **plano de regresión** (y no una “simple” línea). Para nuestro ejemplo, este plano se calcula como:

$$E(ventas_i) = \beta_1 + \beta_2 precio_i + \beta_3 publicidad_i$$

¿Qué significa ahora β_2 ? ¿Y qué significa β_3 ?

¿Qué significa “mantener constante”?

En la pregunta:

¿Cómo se asocian el precio y las ventas *manteniendo constante la publicidad?*

¿Qué significa la frase “mantener constante”? Significa estudiar cómo cambian las ventas cuando cambia uno de los factores, *sin modificar el otro*. Esta es la interpretación de los parámetros del modelo:

- β_2 compara las ventas esperadas cuando cambia el precio, *para un mismo nivel de publicidad*.
- β_3 compara las ventas esperadas cuando cambia la publicidad, *para un mismo nivel de precio*.

Por esta razón, β_2 y β_3 se conocen como **coeficientes de regresión parcial** o **pendientes**.

Mínimos cuadrados ordinarios

Mínimos cuadrados ordinarios

Al igual que en regresión lineal simple, nuestro objetivo consiste en encontrar estimadores para los coeficientes $\beta_1, \beta_2, \beta_3$, los cuales llamaremos b_1, b_2, b_3 , respectivamente. Como antes, usaremos el método de los Mínimos Cuadrados Ordinarios (MCO):

$$\min_{b_1, b_2, b_3} RSS = \min_{b_1, b_2, b_3} \sum_{i=1}^n e_i^2$$

En este caso:

$$\begin{aligned} e_i &= y_i - \hat{y}_i \\ &= y_i - b_1 - b_2 x_{2i} - b_3 x_{3i} \end{aligned}$$

Nota que la idea detrás de la estimación por MCO es la misma de antes, *lo que cambia es la dimensión del problema*.

Estimadores de mínimos cuadrados ordinarios

Ejercicio

Muestra que los estimadores de MCO para este caso son:

$$b_1 = \bar{y} - b_2 \bar{x}_2 - b_3 \bar{x}_3$$

$$b_2 = \frac{\text{Cov}(x_{2i}, y_i) \text{Var}(x_{3i}) - \text{Cov}(x_{3i}, y_i) \text{Cov}(x_{2i}, x_{3i})}{\text{Var}(x_{2i}) \text{Var}(x_{3i}) - [\text{Cov}(x_{2i}, x_{3i})]^2}$$

$$b_3 = \frac{\text{Cov}(x_{3i}, y_i) \text{Var}(x_{2i}) - \text{Cov}(x_{2i}, y_i) \text{Cov}(x_{2i}, x_{3i})}{\text{Var}(x_{2i}) \text{Var}(x_{3i}) - [\text{Cov}(x_{2i}, x_{3i})]^2}$$

De los parámetros a los estimadores (1/2)

Ejemplo

Para el ejemplo de ventas en función del precio y gasto en publicidad tenemos:

Ventas de comida rápida (hamburguesas) en función de su precio y del gasto en publicidad

Término	Coeficiente	Desv. Estándar	Estadístico t	Valor p
Constante	118.913610	6.351638	18.722	< 0.001
Precio	-7.907854	1.095993	-7.215	< 0.001
Publicidad	1.862584	0.683195	2.726	0.00804

De los parámetros a los estimadores (2/2)

Ejercicio

Interpreta los estimadores del modelo de ventas en función del precio y del gasto en publicidad.

Recuerda: ya hemos visto cómo se interpretan los parámetros en:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i.$$

¿Qué información nos proporcionan ahora b_2 y b_3 sobre la relación entre ventas, precio y publicidad?

El modelo con $k - 1$ regresores

Del caso particular al modelo general

Hasta ahora hemos trabajado con dos regresores:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i.$$

Pero podemos representar y_i como función de $k - 1$ regresores:

$$y_i = \beta_1 + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + u_i.$$

Necesitamos una forma más compacta de representar y trabajar con este modelo.

Reglas de álgebra lineal (1/4)

Queda claro que necesitamos una manera diferente de hacer los cálculos. Para esto, resultará útil recordar las siguientes reglas del álgebra matricial:

1. Sean A y B , dos matrices que se pueden sumar. Entonces:

$$(A + B)^{\top} = A^{\top} + B^{\top}$$

2. Sean A y B , dos matrices que se pueden multiplicar. Entonces:

$$(AB)^{\top} = B^{\top}A^{\top}$$

Reglas de álgebra lineal (2/4)

Nota que la regla anterior también implica que si A, B, C son tres matrices que se pueden multiplicar:

$$(ABC)^{\top} = C^{\top} B^{\top} A^{\top}$$

Esto último también aplica para la inversa. Es decir, si A y B son matrices cuadradas e invertibles:

$$(AB)^{-1} = B^{-1} A^{-1}$$

Reglas de álgebra lineal (3/4)

3. Sea D una matriz de dimensión $(n \times 1)$. Entonces:

$$D^T D = \begin{pmatrix} D_1 & D_2 & \cdots & D_n \end{pmatrix} \begin{pmatrix} D_1 \\ D_2 \\ \vdots \\ D_n \end{pmatrix}$$
$$= \sum_{i=1}^n D_i^2$$

4. Sea A una matriz simétrica. Entonces:

$$(A^{-1})^T = (A^T)^{-1}$$
$$= A^{-1}$$

Reglas de álgebra lineal (4/4)

5. Sea X una matriz de dimensión $(n \times k)$, A un vector de dimensión $(k \times 1)$, y Y un vector de dimensión $(n \times 1)$. Entonces:

$$\frac{\partial A^T X^T Y}{\partial A} = X^T Y$$
$$\frac{\partial A^T X^T X A}{\partial A} = 2X^T X A$$

6. Sea X una matriz de dimensión $(n \times k)$. Si X tiene rango columna completo, es decir,

$$\text{rank}(X) = k,$$

entonces $X^T X$ es definida positiva y, por tanto, invertible:

$$(X^T X)^{-1}$$

existe.

El modelo de regresión múltiple en forma matricial (1/3)

Con $k - 1$ regresores (es decir, k coeficientes), el modelo se vuelve:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + \cdots + \beta_k x_{ki} + u_i$$

Este puede representarse en forma matricial como:

$$\mathbf{y} = \mathbf{x}\boldsymbol{\beta} + \mathbf{u}$$

El modelo de regresión múltiple en forma matricial (2/3)

A su vez, el modelo estimado es:

$$\hat{y}_i = b_1 + b_2 x_{2i} + b_3 x_{3i} + \cdots + b_k x_{ki}$$

o, en forma matricial:

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{b}$$

donde $\mathbf{b}$ es el vector de estimadores MCO de $\boldsymbol{\beta}$.

El modelo de regresión múltiple en forma matricial (3/3)

Además, podemos definir el vector de residuales de la regresión como:

$$\begin{aligned}\mathbf{e} &= \mathbf{y} - \hat{\mathbf{y}} \\ &= \mathbf{y} - \mathbf{xb}\end{aligned}$$

Nota que $\mathbf{e}$ es un vector de dimensión $n \times 1$, por lo que:

$$\begin{aligned}\mathbf{e}^\top \mathbf{e} &= \sum_{i=1}^n e_i^2 \\ &= RSS\end{aligned}$$

Derivación de los estimadores de MCO

Ejercicio

Muestra que:

$$RSS = \mathbf{y}^\top \mathbf{y} - 2\mathbf{b}^\top \mathbf{x}^\top \mathbf{y} + \mathbf{b}^\top \mathbf{x}^\top \mathbf{x} \mathbf{b}$$

Muestra finalmente que, la minimización del RSS resulta en:

$$\mathbf{b} = (\mathbf{x}^\top \mathbf{x})^{-1} (\mathbf{x}^\top \mathbf{y})$$

Este es el vector de estimadores de MCO.

Propiedades de los estimadores de MCO

Supuestos del modelo de regresión múltiple (1/7)

Para mostrar las propiedades de los coeficientes estimados, necesitamos primero conocer cuáles son los supuestos del modelo de regresión múltiple:

1. El modelo es *lineal en sus parámetros* y está correctamente especificado:

$$\mathbf{y} = \mathbf{x}\boldsymbol{\beta} + \mathbf{u}$$

Supuestos del modelo de regresión múltiple (2/7)

2. No existe **multicolinealidad perfecta**. Esto es: *ningún regresor puede escribirse como una combinación lineal exacta de los demás*. En términos matriciales, esto requiere que:

$$\text{rank}(\mathbf{X}) = k$$

Y, como consecuencia:

$$\det(\mathbf{X}^T \mathbf{X}) \neq 0$$

¿Qué implica este resultado para la matriz $\mathbf{X}^T \mathbf{X}$?

Supuestos del modelo de regresión múltiple (3/7)

Los demás supuestos (los **supuestos de Gauss-Markov sobre el error**) son los mismos que para el modelo de regresión simple, pero ahora podemos expresarlos también en lenguaje matricial:

3. El valor esperado del error es igual a cero para todas las observaciones:

$$\mathbb{E}(u_i) = 0 \quad \forall i.$$

Nota que:

$$\mathbf{u} = \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix} \Rightarrow \mathbb{E}(\mathbf{u}) = \begin{bmatrix} \mathbb{E}(u_1) \\ \mathbb{E}(u_2) \\ \vdots \\ \mathbb{E}(u_n) \end{bmatrix} = \mathbf{0}.$$

Supuestos del modelo de regresión múltiple (4/7)

4. La varianza del error es constante para todas las observaciones (**homoscedasticidad**):

$$\begin{aligned}\mathbb{V}ar(u_i) &= \mathbb{E}(u_i^2) \\ &= \sigma_i^2 \\ &= \sigma^2; \forall i\end{aligned}$$

5. La covarianza entre los errores de cualesquiera dos observaciones es cero. Este es el supuesto de la **no autocorrelación**:

$$\begin{aligned}\mathbb{C}ov(u_i, u_j) &= \mathbb{E}(u_i u_j) \\ &= 0; \forall i \neq j\end{aligned}$$

Supuestos del modelo de regresión múltiple (5/7)

Ejercicio

Si definimos como $\mathbf{\Omega} = \mathbb{V}ar(\mathbf{u})$ a la **matriz de varianzas y covarianzas de los errores**, muestra que los supuestos 3, 4 y 5 del modelo de regresión lineal múltiple implican que:

$$\begin{aligned}\mathbf{\Omega} &= \mathbb{E}(\mathbf{u}\mathbf{u}^T) \\ &= \sigma^2 \mathbf{I}_n\end{aligned}$$

Supuestos del modelo de regresión múltiple (6/7)

6. Los regresores son **exógenos**: no están relacionados sistemáticamente con el término de error. Si suponemos que las $\mathbf{x}_i$ son *deterministas*, esto implica que:

$$\begin{aligned}\mathbb{E}(\mathbf{x}^T \mathbf{u}) &= \mathbf{x}^T \mathbb{E}(\mathbf{u}) \\ &= \mathbf{0}.\end{aligned}$$

Nota. Si los regresores fueran estocásticos (lo cual es posible), sería necesario establecer supuestos adicionales sobre su relación con los errores.

Supuestos del modelo de regresión múltiple (7/7)

7. (*Conveniencia*). Finalmente, para realizar inferencia exacta en muestras finitas, suponemos que el vector de errores sigue una distribución normal:

$$\mathbf{u} \sim \square(\mathbf{0}, \sigma^2 \mathbf{I}_n).$$

Al igual que en regresión lineal simple, la normalidad no es necesaria para demostrar el teorema de Gauss-Markov.

Propiedades de los estimadores de MCO

Los supuestos anteriores nos permiten estudiar algunas de las principales propiedades de los estimadores de MCO:

- **Insesgados:**

$$\mathbb{E}(\mathbf{b}) = \boldsymbol{\beta}$$

- **Eficientes:** dentro de la clase de estimadores lineales e insesgados para $\boldsymbol{\beta}$, $\mathbf{b}$ es el de mínima varianza.
- **Consistentes:** bajo condiciones regulares adicionales, los estimadores de $\boldsymbol{\beta}$ convergen en probabilidad a sus verdaderos parámetros cuando $n \rightarrow \infty$.

Los estimadores son insesgados

Ejercicio

Demuestra que, si se cumplen los supuestos de Gauss-Markov:

$$\mathbb{E}(\mathbf{b}) = \boldsymbol{\beta}$$

Pista. Primero muestra que $\mathbf{b}$ puede escribirse de la forma:

$$\mathbf{b} = \boldsymbol{\beta} + (\mathbf{x}^\top \mathbf{x})^{-1} (\mathbf{x}^\top \mathbf{u})$$

Los estimadores son eficientes (1/5)

Al igual que en el modelo de regresión simple, para saber si los estimadores de MCO son eficientes, primero tenemos que calcular su varianza:

$$\begin{aligned}\mathbb{V}ar(\mathbf{b}) &= \mathbb{E} \left([\mathbf{b} - \mathbb{E}(\mathbf{b})] [\mathbf{b} - \mathbb{E}(\mathbf{b})]^\top \right) \\ &= \mathbb{E} \left([\mathbf{b} - \boldsymbol{\beta}] [\mathbf{b} - \boldsymbol{\beta}]^\top \right)\end{aligned}$$

Nota que la $\mathbb{V}ar(\mathbf{b})$ es una matriz de dimensión $(k \times k)$.

Los estimadores son eficientes (2/5)

Ejercicio

Dado que:

$$\mathbb{V}ar(\mathbf{u}) = \sigma^2 \mathbf{I}_n,$$

muestra que:

$$\mathbb{V}ar(\mathbf{b}) = \sigma^2 (\mathbf{x}^\top \mathbf{x})^{-1}$$

Los estimadores son eficientes (3/5)

Para mostrar que los estimadores de MCO son los de varianza mínima, definamos primero toda la gama posible de diferentes estimadores lineales para β :

$$\begin{aligned}\tilde{\mathbf{b}} &= \mathbf{c}\mathbf{y}; \\ \mathbf{c} &= (\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top + \mathbf{d}\end{aligned}$$

donde $\mathbf{d}$ es una matriz de dimensión $(k \times n)$. Nota que esta gama incluye a los estimadores de MCO en tanto que $\mathbf{d}$ sea una matriz nula.

Los estimadores son eficientes (4/5)

Ejercicio

Muestra que la gama de estimadores que hemos definido es insesgada en tanto que:

$$\mathbf{dx} = \mathbf{0}$$

Muestra además que, si $\tilde{\mathbf{b}}$ es insesgado:

$$\mathbb{V}ar(\tilde{\mathbf{b}}) = \sigma^2 \left[(\mathbf{x}^\top \mathbf{x})^{-1} + \mathbf{dd}^\top \right]$$

Los estimadores son eficientes (5/5)

Nota que:

$$\begin{aligned}\mathbb{V}ar(\tilde{\mathbf{b}}) &= \sigma^2 (\mathbf{x}^\top \mathbf{x})^{-1} + \sigma^2 \mathbf{d} \mathbf{d}^\top \\ &= \mathbb{V}ar(\mathbf{b}) + \sigma^2 \mathbf{d} \mathbf{d}^\top\end{aligned}$$

Dado que la matriz $\mathbf{d} \mathbf{d}^\top$ es semidefinida positiva (esto es, para todo $\mathbf{v}$, $\mathbf{v}^\top \mathbf{d} \mathbf{d}^\top \mathbf{v} = \|\mathbf{d}^\top \mathbf{v}\|^2 \geq 0$), se sigue que:

$$\mathbb{V}ar(\tilde{\mathbf{b}}) \geq \mathbb{V}ar(\mathbf{b})$$

con igualdad solo si $\mathbf{d} = \mathbf{0}$.

Por lo tanto, bajo los supuestos de Gauss-Markov, *los estimadores de MCO son los estimadores lineales e insesgados de mínima varianza*. Este resultado es el **Teorema de Gauss-Markov** para el modelo de regresión múltiple.

Los estimadores son consistentes

Ejercicio*

Demuestra que los estimadores de MCO son consistentes, es decir:

$$\text{plim}(\mathbf{b}) = \boldsymbol{\beta}$$

Pista. Demuestra primero que $\mathbf{b}$ puede escribirse como:

$$\mathbf{b} = \boldsymbol{\beta} + \left(\frac{\mathbf{x}^\top \mathbf{x}}{n} \right)^{-1} \left(\frac{\mathbf{x}^\top \mathbf{u}}{n} \right)$$

Varianza de b y su estimador

La matriz aniquiladora (1/3)

Antes de continuar, notemos que conocemos la expresión para la varianza de los estimadores, pero no podemos calcularla porque desconocemos σ^2 . Por tanto, necesitamos estimarla.

Recordemos que:

$$\mathbf{b} = (\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top \mathbf{y}$$
$$\mathbf{e} = \mathbf{y} - \mathbf{x}\mathbf{b}$$

Y, si $\mathbf{b}$ es el estimador de MCO de los coeficientes del modelo:

$$\mathbf{e} = \mathbf{M}_x \mathbf{y}$$
$$\mathbf{M}_x = \mathbf{I}_n - \mathbf{x}(\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top$$

La matriz $\mathbf{M}_x$ se conoce como **matriz aniquiladora** o **matriz generadora de residuos**.

La matriz aniquiladora (2/3)

Ejercicio

Mostrar que la matriz $\mathbf{M}_x$ cumple con las siguientes propiedades:

1. Es *simétrica*:

$$\mathbf{M}_x^\top = \mathbf{M}_x$$

2. Es *idempotente*:

$$\begin{aligned}\mathbf{M}_x \mathbf{M}_x &= \mathbf{M}_x^2 \\ &= \mathbf{M}_x\end{aligned}$$

La matriz aniquiladora (3/3)

Ejercicio (cont'd)

3. Es ortogonal a las columnas de $\mathbf{x}$:

$$\mathbf{M}_x \mathbf{x} = \mathbf{0}$$

4. Mostrar que esta última propiedad implica que el vector de residuales también es ortogonal a las columnas de $\mathbf{x}$:

$$\mathbf{x}^\top \mathbf{e} = \mathbf{0}$$

Traza de una matriz (1/2)

También será importante recordar qué es la **traza de una matriz** y sus propiedades.

Definición

Sea $\mathbf{A}$ una matriz cuadrada de dimensión $(k \times k)$, cuyo elemento en el i -ésimo renglón y j -ésima columna es a_{ij} .

La traza de una matriz es:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^k a_{jj}$$

Traza de una matriz (2/2)

Consideremos ahora una constante c , un vector de tamaño $(n \times 1)$, $\mathbf{b}$, y matrices $\mathbf{A}, \mathbf{B}, \mathbf{C}, \mathbf{D}$ de dimensiones compatibles.

Entonces:

$$1. \operatorname{tr}(c\mathbf{A}) = c \operatorname{tr}(\mathbf{A})$$

$$2. \operatorname{tr}(\mathbf{A}^\top) = \operatorname{tr}(\mathbf{A})$$

$$3. \operatorname{tr}(\mathbf{A} + \mathbf{B}) = \operatorname{tr}(\mathbf{A}) + \operatorname{tr}(\mathbf{B})$$

$$4. \operatorname{tr}(\mathbf{I}_k) = k$$

$$5. \operatorname{tr}(\mathbf{AB}) = \operatorname{tr}(\mathbf{BA})$$

$$6. \operatorname{tr}(\mathbf{ABCD}) = \operatorname{tr}(\mathbf{BCDA}) = \operatorname{tr}(\mathbf{CDAB}) = \operatorname{tr}(\mathbf{DABC})$$

$$7. \mathbf{b}^\top \mathbf{b} = \operatorname{tr}(\mathbf{b}^\top \mathbf{b}) = \operatorname{tr}(\mathbf{bb}^\top)$$

Estimador para la varianza de $\mathbf{b}$ (1/3)

Una vez que tenemos todas las herramientas necesarias, podemos encontrar un estimador insesgado para la varianza de los errores, σ^2 . Llamaremos a este estimador s^2 .

Se puede demostrar que:

$$\begin{aligned}s^2 &= \frac{\mathbf{e}^\top \mathbf{e}}{n - k} \\ &= \frac{RSS}{n - k}\end{aligned}$$

Naturalmente, esto implica que:

$$\widehat{\text{Var}}(\mathbf{b}) = s^2(\mathbf{X}^\top \mathbf{X})^{-1}$$

Estimador para la varianza de $\mathbf{b}$ (2/3)

Ejercicio

Demostrar que s^2 es un estimador insesgado de σ^2 .

Pista.

Primero demuestra que $\mathbf{e} = \mathbf{M}_x \mathbf{u}$ y luego que:

$$\mathbb{E}(\mathbf{e}^\top \mathbf{e}) = \sigma^2 \text{tr}(\mathbf{M}_x)$$

Finalmente, utiliza la expresión de $\mathbf{M}_x$ y las propiedades de la traza para llegar al resultado deseado.

Estimador para la varianza de $\mathbf{b}$ (3/3)

Ejercicio

Ventas de comida rápida (hamburguesas) en función de su precio y del gasto en publicidad

Término	Coeficiente	Desv. Estándar	Estadístico t	Valor p
Constante	118.913610	6.351638	18.722	< 0.001
Precio	-7.907854	1.095993	-7.215	< 0.001
Publicidad	1.862584	0.683195	2.726	0.00804

Nota: La mayoría de los programas econométricos reportan los **errores estándar** de los coeficientes estimados, que corresponden a la raíz cuadrada de los elementos de la diagonal principal de $\widehat{\text{Var}}(\mathbf{b})$.

Bondad de ajuste, la R^2 y la R^2 ajustada

La R^2 en el modelo de regresión múltiple (1/2)

Recordemos que:

$$\begin{aligned} R^2 &= 1 - \frac{RSS}{TSS} \\ &= 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \end{aligned}$$

Esta expresión se puede escribir en forma matricial:

$$R^2 = 1 - \frac{\mathbf{e}^\top \mathbf{e}}{(\mathbf{y} - \bar{y}\mathbf{1})^\top (\mathbf{y} - \bar{y}\mathbf{1})}$$

donde $\mathbf{1}$ es un vector de unos de dimensión $(n \times 1)$.

La R^2 en el modelo de regresión múltiple (2/2)

Ejercicio*

Demuestra que la R^2 nunca disminuye cuando agregamos nuevas variables explicativas al modelo.

Intuición

Al agregar un nuevo regresor, MCO tiene una posibilidad adicional para minimizar la suma de cuadrados de los residuos. En el peor de los casos, puede asignarle un coeficiente igual a cero. Por tanto:

$$RSS_{\text{ampliado}} \leq RSS_{\text{original}}$$

y, dado que TSS no cambia:

$$R^2_{\text{ampliado}} \geq R^2_{\text{original}}.$$

¿Significa esto que debemos agregar tantas variables como sea posible?

La R^2 ajustada (1/3)

Para tomar en cuenta el número de regresores incluidos en el modelo, podemos utilizar la R^2 ajustada, $\bar{R}^2$:

$$\begin{aligned}\bar{R}^2 &= 1 - \frac{\mathbf{e}^\top \mathbf{e} / (n - k)}{(\mathbf{y} - \bar{y}\mathbf{1})^\top (\mathbf{y} - \bar{y}\mathbf{1}) / (n - 1)} \\ &= 1 - (1 - R^2) \frac{n - 1}{n - k}\end{aligned}$$

Nota que, conforme k se incrementa, el efecto final sobre la $\bar{R}^2$ es ambiguo.

La R^2 ajustada (2/3)

Teorema

Consideremos dos modelos que difieren únicamente en la inclusión de un regresor adicional.

La inclusión del nuevo regresor:

- siempre incrementa o mantiene constante la R^2 ;
- incrementa la $\bar{R}^2$ únicamente si el valor absoluto del estadístico t asociado al nuevo coeficiente es mayor que 1:

$$|t| > 1.$$

Por tanto, a diferencia de la R^2 , la $\bar{R}^2$ puede disminuir cuando agregamos una nueva variable explicativa.

La R^2 ajustada (3/3)

Ejemplo

Ventas de comida rápida (hamburguesas) en función de su precio y del gasto en publicidad.

Media de la vble. dep.	77.374667	D.T. de la vble. dep.	6.488537
Suma de cuad. residuos	1,718.94	D.T. de la regresión	4.886124
R-cuadrado	0.448258	R-cuadrado corregido	0.432932
F(2, 72)	29.247859	Valor p (de F)	5.04e-10
Log-verosimilitud	-223.8695	Criterio de Akaike	455.739
Criterio de Schwarz	465.009	Crit. de Hannan-Quinn	456.515

Resumen

¿Qué hemos aprendido?

Cuando varios factores cambian al mismo tiempo, ¿cómo podemos estudiar la relación entre y y uno de ellos manteniendo constantes los demás?

Para responderla aprendimos a:

- Extender el modelo de regresión para incorporar múltiples variables explicativas;
- Interpretar los coeficientes como relaciones parciales, manteniendo constantes los demás regresores;
- Estimar los parámetros mediante mínimos cuadrados ordinarios;
- Representar el modelo y sus supuestos utilizando álgebra matricial;
- Demostrar las propiedades de los estimadores de MCO;
- Estimar la matriz de varianzas y covarianzas de los estimadores;
- Evaluar la bondad de ajuste mediante la R^2 y la R^2 ajustada.

¿Qué sigue?

Hasta ahora, hemos aprendido a estimar las relaciones entre múltiples variables y a estudiar las propiedades de los estimadores de MCO. Pero nuestras estimaciones provienen de una muestra y, por tanto, están sujetas a incertidumbre. En el siguiente capítulo aprenderemos a utilizar esa información para realizar **inferencia estadística** sobre los parámetros del modelo.