# Econometría

## *Multicolinealidad*

Alejandro Mosiño - *Universidad de Guanajuato*

v.2026.10.27

# ¿Qué información aporta cada regresor?

# ¿Podemos distinguir sus efectos?

En regresión lineal múltiple estudiamos, por ejemplo:

$$ventas_i = \beta_1 + \beta_2 precio_i + \beta_3 publicidad_i + u_i$$

Interpretamos $\beta_2$ como la relación entre el precio y la media de las ventas, *manteniendo constante la publicidad*.

> **Pero ¿qué ocurre si, en nuestros datos, el precio y la publicidad casi siempre cambian al mismo tiempo?**

# Multicolinealidad perfecta

# Cuando dos regresores contienen la misma información

Consideremos el modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i$$

Supongamos que, para todas las observaciones:

$$x_{3i} = \tau x_{2i}$$

donde $\tau$ es una constante distinta de cero. *¿Qué implica esta relación para la estimación de $\beta_2$ y $\beta_3$?*

# ¿Qué podemos estimar?

Si $x_{3i} = \tau x_{2i}$, entonces:

$$\begin{aligned} y_i &= \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i \\ &= \beta_1 + \beta_2 x_{2i} + \tau\beta_3 x_{2i} + u_i \\ &= \beta_1 + (\beta_2 + \tau\beta_3) x_{2i} + u_i \,. \end{aligned}$$

Los datos permiten distinguir la combinación $\beta_2 + \tau\beta_3$, pero no los dos coeficientes por separado.

> **¿Por qué diferentes valores de $\beta_2$ y $\beta_3$ pueden representar el mismo modelo?**

# ¿Qué ocurre con la matriz de regresores?

Si $x_{3i} = \tau x_{2i}$, la matriz de regresores es:

$$\mathbf{x} = \begin{pmatrix} 1 & x_{12} & \tau x_{12} \\ 1 & x_{22} & \tau x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{n2} & \tau x_{n2} \end{pmatrix}$$

La tercera columna es un múltiplo exacto de la segunda. Por tanto:

$$\text{rank}(\mathbf{x}) < 3.$$

¿Qué implica esto para la estimación mediante MCO?

# ¿Qué ocurre con $\mathbf{x}^\top\mathbf{x}$?

Recordemos que el estimador MCO se obtiene a partir de la matriz $\mathbf{x}^\top\mathbf{x}$. En nuestro ejemplo, esta es:

$$\mathbf{x}^\top\mathbf{x} = \begin{pmatrix} n & \sum_i x_{2i} & \tau\sum_i x_{2i} \\ \sum_i x_{2i} & \sum_i x_{2i}^2 & \tau\sum_i x_{2i}^2 \\ \tau\sum_i x_{2i} & \tau\sum_i x_{2i}^2 & \tau^2\sum_i x_{2i}^2 \end{pmatrix}$$

Observa las columnas de esta matriz. ¿Qué puedes concluir sobre su determinante?

# Determinante de la matriz $\mathbf{x}^\top \mathbf{x}$ (1/2)

**Ejercicio**

Muestra que:

$$\det(\mathbf{x}^\top \mathbf{x}) = 0.$$

*Pista.* Sea $\mathbf{A}$ una matriz de dimensión $k \times k$. Recuerda que el determinante de $\mathbf{A}$ se calcula como:

$$|\mathbf{A}| = \sum_{i_1}^{k} (-1)^{i+1} \mathbf{A}_{ij} |\mathbf{A}^{(i,j)}|$$

donde $\mathbf{A}_{ij}$ es el elemento $(i, j)$ de la matriz $\mathbf{A}$ y $\mathbf{A}^{(i,j)}$ es la matriz $\mathbf{A}$ una vez eliminados su $i$-ésimo renglón y su $j$-ésima columna. Nota que uno es libre de elegir el valor de $j$.

# Determinante de la matriz $\mathbf{X}^\top \mathbf{X}$ (2/2)

*Pista*. Considera las matrices:

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}, \qquad \widetilde{A} = \begin{pmatrix} a + \tau b & b \\ c + \tau d & d \end{pmatrix}.$$

1. Calcula $\det(A)$ y $\det(\widetilde{A})$.
2. Compara y comenta los resultados.

# ¿Qué implica para MCO?

Hemos demostrado que:

$$\det(\mathbf{x}^\top \mathbf{x}) = 0.$$

Por tanto, $\mathbf{x}^\top \mathbf{x}$ no es invertible, por lo que no podemos utilizar la fórmula:

$$\mathbf{b} = (\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top \mathbf{y}$$

**Distintos vectores de coeficientes pueden producir exactamente los mismos valores ajustados y el mismo RSS.**

# Presión arterial y tamaño corporal (1/2)

### Ejercicio

Consideremos un modelo para la presión arterial de 20 pacientes:

$$\begin{aligned} BP_i &= \beta_1 + \beta_2 Age_i + \beta_3 Weight_i + \beta_4 BSA_i \\ &\quad + \beta_5 Dur_i + \beta_6 Pulse_i + \beta_7 Stress_i + u_i \,. \end{aligned}$$

En los datos preparados para este ejercicio se cumple exactamente:

$$Weight_i = 46\, BSA_i \,.$$

*¿Qué esperas que ocurra con la estimación de los coeficientes del peso y la superficie corporal?*

# Presión arterial y tamaño corporal (2/2)

Utilizando los datos de presión arterial:

1. Estima el modelo eliminando $BSA$.
2. Estima nuevamente, pero eliminando $Weight$.
3. Compara los valores ajustados, el RSS y los coeficientes de ambos modelos.

¿Qué ocurre cuando incluimos simultáneamente $Weight$ y $BSA$?

*¿Significa esto que no podemos minimizar el RSS?*

# Multicolinealidad imperfecta

# ¿Qué ocurre cuando la relación entre variables no es exacta?

Aunque el caso de la **multicolinealidad perfecta** puede parecer un caso muy extremo, no imposible. En la práctica, es más frecuente encontrar *regresores fuertemente relacionados sin dependencia exacta*. Por ejemplo, al regresar $x_3$ sobre $x_2$:

$$x_{3i} = \widehat{\gamma}_0 + \widehat{\gamma}_1 x_{2i} + \upsilon_i .$$

Aquí $\upsilon_i$ representa el *residuo de una proyección lineal muestral, no un nuevo error aleatorio*.

¿Qué ocurre con la precisión de MCO cuando la variación de esos residuos es muy pequeña?

# La matriz que determina la precisión

Consideremos el modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i \,.$$

Recordemos que, si se cumplen los supuestos de Gauss-Markov: $\mathrm{Var}(\mathbf{b}) = \sigma^2(\mathbf{x}^\top \mathbf{x})^{-1}$ . Esta puede reexpresarse en términos de la **matriz de productos cruzados**:

$$\mathrm{Var}(\mathbf{b}) = \sigma^2 A^{-1} \,,$$

donde:

$$A = \begin{pmatrix} S_{22} & S_{23} \\ S_{23} & S_{33} \end{pmatrix} \,, \qquad S_{jk} = \sum_{i=1}^{n} (x_{ji} - \bar{x}_j)(x_{ki} - \bar{x}_k), \qquad \bar{x}_j = \frac{1}{n} \sum_{i=1}^{n} x_{ji}$$

# ¿Qué ocurre con la varianza de los estimadores?

Para nuestro modelo con dos regresores, $x_{2i}$ y $x_{3i}$ tenemos que:

$$\text{Var}(b_2) = \frac{\sigma^2}{S_{22}(1 - r_{23}^2)}$$
$$\text{Var}(b_3) = \frac{\sigma^2}{S_{33}(1 - r_{23}^2)}$$

donde $r_{23}$ es el coeficiente de correlación muestral entre los regresores.

Nota que, si mantenemos $\sigma^2$ y $S_{jj}$ constantes, *cuanto más se aproxima $|r_{23}|$ a uno, mayor es la varianza de los estimadores*. ¿Qué ocurre cuando $|r_{23}| = 1$?

# Varianza de los estimadores

### Ejercicio*

Sea $A$ la matriz de productos cruzados de un modelo de regresión con dos regresores.

1. Muestra que:

$$\det(A) = S_{22}S_{33}(1 - r_{23}^2).$$

2. Utilizando $\sigma^2 A^{-1}$ , demuestra que:

$$\text{Var}(b_2) = \frac{\sigma^2}{S_{22}(1 - r_{23}^2)}$$

$$\text{Var}(b_3) = \frac{\sigma^2}{S_{33}(1 - r_{23}^2)}$$

# ¿Cuánta información aporta cada regresor? (1/2)

**Ejercicio***

Consideremos la regresión auxiliar:

$$x_{3i} = \hat{\gamma}_0 + \hat{\gamma}_1 x_{2i} + v_i .$$

Muestra que:

$$R^2 = 1 - \frac{\sum_i v_i^2}{S_{33}}$$

# ¿Cuánta información aporta cada regresor? (2/2)

Ahora, muestra que:

$$R^2 = r_{23}^2$$

Lo anterior implica que la RSS del modelo auxuliar puede expresarse como:

$$\sum_i v_i^2 = S_{33}(1 - r_{23}^2).$$

*¿Qué sucede con la suma de cuadrados de los residuos cuando $|r_{23}|$ se aproxima a uno?*

# ¿Cómo afecta esto a la precisión?

Los resultados anteriores nos permiten demostrar que:

$$\mathrm{Var}(b_3) = \frac{\sigma^2}{\sum_i v_i^2}$$

Esto implica que *cuanto menor sea la variación de* $x_3$ *que no puede explicarse mediante* $x_2$*, menor será la precisión de* $b_3$*.*

*Nota:* recuerda el teorema de Frisch–Waugh–Lovell. ¿Cómo se relaciona este resultado con la estimación del coeficiente de regresión parcial?

# Material en preparación

Las siguientes secciones de este capítulo aún están en revisión y se incorporarán próximamente.