Econometría

Multicolinealidad

Alejandro Mosiño - *Universidad de Guanajuato*

v.2026.10.27

¿Qué información aporta cada regresor?

¿Podemos distinguir sus efectos?

En regresión lineal múltiple estudiamos, por ejemplo:

$$ventas_i = \beta_1 + \beta_2 precio_i + \beta_3 publicidad_i + u_i$$

Interpretamos β_2 como la relación entre el precio y la media de las ventas, *manteniendo constante la publicidad*.

> **Pero ¿qué ocurre si, en nuestros datos, el precio y la publicidad casi siempre cambian al mismo tiempo?**

Multicolinealidad perfecta

Cuando dos regresores contienen la misma información

Consideremos el modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i$$

Supongamos que, para todas las observaciones:

$$x_{3i} = \tau x_{2i}$$

donde τ es una constante distinta de cero. *¿Qué implica esta relación para la estimación de β_2 y β_3?*

¿Qué podemos estimar?

Si $x_{3i} = \tau x_{2i}$, entonces:

$$\begin{aligned} y_i &= \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i \\ &= \beta_1 + \beta_2 x_{2i} + \tau\beta_3 x_{2i} + u_i \\ &= \beta_1 + (\beta_2 + \tau\beta_3) x_{2i} + u_i \,. \end{aligned}$$

Los datos permiten distinguir la combinación $\beta_2 + \tau\beta_3$, pero no los dos coeficientes por separado.

> **¿Por qué diferentes valores de β_2 y β_3 pueden representar el mismo modelo?**

¿Qué ocurre con la matriz de regresores?

Si $x_{3i} = \tau x_{2i}$, la matriz de regresores es:

$$\mathbf{x} = \begin{pmatrix} 1 & x_{12} & \tau x_{12} \\ 1 & x_{22} & \tau x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{n2} & \tau x_{n2} \end{pmatrix}$$

La tercera columna es un múltiplo exacto de la segunda. Por tanto:

$$\text{rank}(\mathbf{x}) < 3.$$

¿Qué implica esto para la estimación mediante MCO?

¿Qué ocurre con $\mathbf{x}^\top\mathbf{x}$?

Recordemos que el estimador MCO se obtiene a partir de la matriz $\mathbf{x}^\top\mathbf{x}$. En nuestro ejemplo, esta es:

$$\mathbf{x}^\top\mathbf{x} = \begin{pmatrix} n & \sum_i x_{2i} & \tau\sum_i x_{2i} \\ \sum_i x_{2i} & \sum_i x_{2i}^2 & \tau\sum_i x_{2i}^2 \\ \tau\sum_i x_{2i} & \tau\sum_i x_{2i}^2 & \tau^2\sum_i x_{2i}^2 \end{pmatrix}$$

Observa las columnas de esta matriz. ¿Qué puedes concluir sobre su determinante?

Determinante de la matriz $\mathbf{x}^\top \mathbf{x}$ (1/2)

Ejercicio

Muestra que:

$$\det(\mathbf{x}^\top \mathbf{x}) = 0.$$

Pista. Sea $\mathbf{A}$ una matriz de dimensión $k \times k$. Recuerda que el determinante de $\mathbf{A}$ se calcula como:

$$|\mathbf{A}| = \sum_{i_1}^{k} (-1)^{i+1} \mathbf{A}_{ij} |\mathbf{A}^{(i,j)}|$$

donde $\mathbf{A}_{ij}$ es el elemento (i, j) de la matriz $\mathbf{A}$ y $\mathbf{A}^{(i,j)}$ es la matriz $\mathbf{A}$ una vez eliminados su i-ésimo renglón y su j-ésima columna. Nota que uno es libre de elegir el valor de j.

Determinante de la matriz $\mathbf{X}^\top \mathbf{X}$ (2/2)

Pista. Considera las matrices:

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}, \qquad \widetilde{A} = \begin{pmatrix} a + \tau b & b \\ c + \tau d & d \end{pmatrix}.$$

1. Calcula $\det(A)$ y $\det(\widetilde{A})$.
2. Compara y comenta los resultados.

¿Qué implica para MCO?

Hemos demostrado que:

$$\det(\mathbf{x}^\top \mathbf{x}) = 0.$$

Por tanto, $\mathbf{x}^\top \mathbf{x}$ no es invertible, por lo que no podemos utilizar la fórmula:

$$\mathbf{b} = (\mathbf{x}^\top \mathbf{x})^{-1} \mathbf{x}^\top \mathbf{y}$$

Distintos vectores de coeficientes pueden producir exactamente los mismos valores ajustados y el mismo RSS.

Presión arterial y tamaño corporal (1/2)

Ejercicio

Consideremos un modelo para la presión arterial de 20 pacientes:

$$\begin{aligned} BP_i &= \beta_1 + \beta_2 Age_i + \beta_3 Weight_i + \beta_4 BSA_i \\ &\quad + \beta_5 Dur_i + \beta_6 Pulse_i + \beta_7 Stress_i + u_i \,. \end{aligned}$$

En los datos preparados para este ejercicio se cumple exactamente:

$$Weight_i = 46\, BSA_i \,.$$

¿Qué esperas que ocurra con la estimación de los coeficientes del peso y la superficie corporal?

Presión arterial y tamaño corporal (2/2)

Utilizando los datos de presión arterial:

1. Estima el modelo eliminando BSA.
2. Estima nuevamente, pero eliminando $Weight$.
3. Compara los valores ajustados, el RSS y los coeficientes de ambos modelos.

¿Qué ocurre cuando incluimos simultáneamente $Weight$ y BSA?

¿Significa esto que no podemos minimizar el RSS?

Multicolinealidad imperfecta

¿Qué ocurre cuando la relación entre variables no es exacta?

Aunque el caso de la **multicolinealidad perfecta** puede parecer un caso muy extremo, no imposible. En la práctica, es más frecuente encontrar *regresores fuertemente relacionados sin dependencia exacta*. Por ejemplo, al regresar x_3 sobre x_2:

$$x_{3i} = \widehat{\gamma}_0 + \widehat{\gamma}_1 x_{2i} + v_i.$$

Aquí v_i representa el *residuo de una proyección lineal muestral, no un nuevo error aleatorio*.

¿Qué ocurre con la precisión de MCO cuando la variación de esos residuos es muy pequeña?

La matriz que determina la precisión

Consideremos el modelo:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i \, .$$

Recordemos que, si se cumplen los supuestos de Gauss-Markov: $\mathrm{Var}(\mathbf{b}) = \sigma^2(\mathbf{x}^\top \mathbf{x})^{-1}$. Esta puede reexpresarse en términos de la **matriz de productos cruzados**:

$$\mathrm{Var}(\mathbf{b}) = \sigma^2 A^{-1} \, ,$$

donde:

$$A = \begin{pmatrix} S_{22} & S_{23} \\ S_{23} & S_{33} \end{pmatrix} , \qquad S_{jk} = \sum_{i=1}^{n} (x_{ji} - \bar{x}_j)(x_{ki} - \bar{x}_k), \qquad \bar{x}_j = \frac{1}{n} \sum_{i=1}^{n} x_{ji}$$

¿Qué ocurre con la varianza de los estimadores?

Para nuestro modelo con dos regresores, x_{2i} y x_{3i} tenemos que:

$$\text{Var}(b_2) = \frac{\sigma^2}{S_{22}(1 - r_{23}^2)}$$
$$\text{Var}(b_3) = \frac{\sigma^2}{S_{33}(1 - r_{23}^2)}$$

donde r_{23} es el coeficiente de correlación muestral entre los regresores.

Nota que, si mantenemos σ^2 y S_{jj} constantes, *cuanto más se aproxima $|r_{23}|$ a uno, mayor es la varianza de los estimadores*. ¿Qué ocurre cuando $|r_{23}| = 1$?

Varianza de los estimadores

Ejercicio*

Sea A la matriz de productos cruzados de un modelo de regresión con dos regresores.

1. Muestra que:

$$\det(A) = S_{22}S_{33}(1 - r_{23}^2).$$

2. Utilizando $\sigma^2 A^{-1}$, demuestra que:

$$\text{Var}(b_2) = \frac{\sigma^2}{S_{22}(1 - r_{23}^2)}$$

$$\text{Var}(b_3) = \frac{\sigma^2}{S_{33}(1 - r_{23}^2)}$$

¿Cuánta información aporta cada regresor? (1/2)

Ejercicio*

Consideremos la regresión auxiliar:

$$x_{3i} = \hat{\gamma}_0 + \hat{\gamma}_1 x_{2i} + v_i .$$

Muestra que:

$$R^2 = 1 - \frac{\sum_i v_i^2}{S_{33}}$$

¿Cuánta información aporta cada regresor? (2/2)

Ahora, muestra que:

$$R^2 = r_{23}^2$$

Lo anterior implica que la RSS del modelo auxuliar puede expresarse como:

$$\sum_i v_i^2 = S_{33}(1 - r_{23}^2).$$

¿Qué sucede con la suma de cuadrados de los residuos cuando $|r_{23}|$ se aproxima a uno?

¿Cómo afecta esto a la precisión?

Los resultados anteriores nos permiten demostrar que:

$$\mathrm{Var}(b_3) = \frac{\sigma^2}{\sum_i v_i^2}$$

Esto implica que *cuanto menor sea la variación de* x_3 *que no puede explicarse mediante* x_2*, menor será la precisión de* b_3*.*

Nota: recuerda el teorema de Frisch–Waugh–Lovell. ¿Cómo se relaciona este resultado con la estimación del coeficiente de regresión parcial?

¿Qué ocurre cuando tenemos más regresores?

Cuando tenemos más regresores, la regresión auxiliar para x_j es:

$$x_{ji} = \widehat{\gamma}_0 + \sum_{\substack{\ell=2 \\ \ell \neq j}}^{k} \widehat{\gamma}_\ell \, x_{\ell i} + v_{ji}.$$

En este caso, los residuales v_j representan la variación de x_j que no puede explicarse linealmente mediante los otros regresores:

$$\sum_i v_{ji}^2 = S_{jj}(1 - R_j^2) \quad \Rightarrow \quad \text{Var}(b_j) = \frac{\sigma^2}{S_{jj}(1 - R_j^2)}.$$

donde R_j^2 es el coeficiente de determinación de la regresión auxiliar para la x_j.

Regresión parcial y precisión (1/2)

Ejercicio*

Considera el modelo:

$$\mathbf{y} = \mathbf{x}\boldsymbol{\beta} + \mathbf{u}.$$

Sea $\mathbf{v}_j$ el vector de residuales de regresar x_j sobre los demás regresores, incluida la constante.

1. Utilizando Frisch–Waugh–Lovell, demuestra que:

$$b_j = \frac{\mathbf{v}_j^\top \mathbf{y}}{\mathbf{v}_j^\top \mathbf{v}_j}.$$

Regresión parcial y precisión (2/2)

2. Bajo los supuestos clásicos, demuestra que:

$$\mathrm{Var}(b_j) = \frac{\sigma^2}{\mathbf{v}_j^\top \mathbf{v}_j}.$$

3. Utiliza el R_j^2 de la regresión auxiliar para recuperar:

$$\mathrm{Var}(b_j) = \frac{\sigma^2}{S_{jj}(1 - R_j^2)}.$$

La dependencia lineal puede involucrar varios regresores, aun sin correlaciones simples elevadas.

El factor de inflación de la varianza

Definimos el **factor de inflación de la varianza** como:

$$VIF_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 es el coeficiente de determinación de la regresión auxiliar de x_j. Entonces:

$$\text{Var}(b_j) = \frac{\sigma^2}{S_{jj}} VIF_j.$$

¿Qué nos dice el VIF? (1/2)

Ejercicio

Nuevamente, consideremos un modelo para la presión arterial de 20 pacientes:

$$\begin{aligned} BP_i = \beta_1 + \beta_2 Age_i + \beta_3 Weight_i + \beta_4 BSA_i \\ + \beta_5 Dur_i + \beta_6 Pulse_i + \beta_7 Stress_i + u_i \,. \end{aligned}$$

A diferencia del ejemplo anterior, ahora:

$$Weight_i = 46\, BSA_i \,.$$

¿Qué esperas que ocurra con el VIF_{Weight} ?

¿Qué nos dice el VIF? (2/2)

Muestra que:

Regresor	VIF
Age	1.763
Weight	8.417
BSA	5.329
Pulse	4.414

Nota que $VIF_{Weight} \approx 8.417$. Esto significa que la varianza de $Weight$ es 8.417 veces la que tendría si esta variable fuera ortogonal a los demás regresores, manteniendo constantes σ^2 y S_{jj}.

¿Podemos concluir que su error estándar es mayor que el de Age?

Consecuencias para la inferencia

¿La multicolinealidad produce sesgo?

Cuando la multicolinealidad es imperfecta, la matriz de regresores conserva su rango completo. Entonces, si se cumplen los supuestos de Gauss-Markov:

$$E(\mathbf{b}) = \boldsymbol{\beta}, \qquad \text{Var}(\mathbf{b}) = \sigma^2(\mathbf{x}^\top \mathbf{x})^{-1}\,.$$

- MCO nos regresa estimadores insesgados.
- Los estimadores de MCO son MELI.
- Pero la precisión de algunos coeficientes puede reducirse.

La multicolinealidad imperfecta no constituye, por sí misma, una violación a los supuestos del modelo de regresión lineal.

¿Qué ocurre con la inferencia individual?

Recordemos el estadístico de la prueba de signficancia individual y su intervalo de confianza:

$$t_j = \frac{b_j - \beta_j^0}{\text{s. e.}(b_j)}; \qquad b_j \pm t_{\alpha/2,n-k}\ \text{s. e.}(b_j).$$

La multicolinealidad puede aumentar la varianza de b_j y, por tanto, su error estándar. Esto puede producir:

- Estadísticos t de menor magnitud.
- Intervalos de confianza más amplios.
- Menor capacidad para detectar efectos individuales.

¿Significa que las pruebas de hipótesis dejan de ser válidas?

¿Toda la información se vuelve imprecisa?

Consideremos nuevamente:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i; \qquad x_{3i} \approx \gamma_0 + \tau x_{2i}$$

Entonces:

$$y_i \approx (\beta_1 + \gamma_0 \beta_3) + (\beta_2 + \tau \beta_3) x_{2i} + u_i .$$

Aunque sea difícil distinguir los efectos individuales de x_2 y x_3, podríamos estimar con mayor precisión la combinación $\beta_2 + \tau \beta_3$.

¿Por qué?

¿Por qué una combinación puede estimarse con precisión?

Ejercicio*

Utilizando la inversa de la matriz de productos cruzados, demuestra que, si

$$\tau = \frac{S_{23}}{S_{22}},$$

entonces:

$$\text{Var}(b_2 + \tau b_3) = \frac{\sigma^2}{S_{22}}.$$

¿Qué implica este resultado?

Diagnóstico de la multicolinealidad

¿Un VIF elevado implica poca precisión?

Ejercicio*

Consideremos dos diseños con $\sigma^2 = 4$:

	Diseño A	Diseño B
S_{jj}	800	100
VIF_j	8	2

1. Calcula la varianza de b_j en ambos diseños.
2. ¿Cuál presenta mayor inflación *relativa* de la varianza?
3. ¿En cuál se estima el coeficiente con mayor precisión?

¿Cuándo debe preocuparnos el VIF?

Recordemos que:

$$VIF_j = \frac{1}{1 - R_j^2} \geq 1.$$

Una regla frecuentemente utilizada es: si $VIF_j = 1$, el regresor es ortogonal a los demás; si $VIF_j > 10$, podría existir un problema importante de multicolinealidad. Además, observa que:

$$VIF_j > 10 \iff R_j^2 > 0.90.$$

El valor de 10 es una referencia orientativa, no una prueba estadística ni un umbral universal.

¿Podría preocuparnos un VIF menor que 10?

¿Qué resultados pueden hacernos sospechar?

Algunas señales que justifican examinar la multicolinealidad son:

- Correlaciones elevadas entre variables explicativas.
- Un R^2 elevado acompañado de coeficientes individuales estimados con poca precisión.
- Cambios importantes en los coeficientes al modificar ligeramente la especificación del modelo.

Sin embargo, *ninguna de estas señales demuestra, por sí sola, que exista un problema importante de multicolinealidad.*

Para evaluar la situación podemos utilizar regresiones auxiliares, el VIF y los índices de condición.

Normalización de la matriz $\mathbf{x}$

Para evitar que las unidades de medición dominen el diagnóstico, normalizamos cada columna de $\mathbf{x}$, incluida la constante:

$$x_{ij}^{*} = \frac{x_{ij}}{\sqrt{\sum_{h=1}^{n} x_{hj}^{2}}}.$$

Esto nos permite construir la *matriz normalizada* $\mathbf{x}^{*}$ y, con esta, la matriz $C = (\mathbf{x}^{*})^{\top}\mathbf{x}^{*}$. Esta última tiene valores propios:

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_k \geq 0.$$

¿Qué nos dicen los valores propios?

Recordemos que:

$$\text{rank}(\mathbf{x}) < k \iff \lambda_k = 0.$$

Entonces:

- Si algún valor propio es cero, existe dependencia lineal exacta.
- Si un valor propio es muy pequeño respecto de los mayores, existe una dirección de dependencia casi exacta.

¿Qué aporta este resultado frente a las correlaciones entre pares de regresores?

Número e índices de condición

Con los valores propios de $C = (\mathbf{x}^*)^\top \mathbf{x}^*$, definimos el **número de condición**, K y el **índice de condición**, IC:

$$K = \frac{\lambda_1}{\lambda_k}, \qquad IC_j = \sqrt{\frac{\lambda_1}{\lambda_j}}.$$

Nota que, cuando $\lambda_k > 0$, $IC_{\max} = \sqrt{K}$. *¿Qué ocurre cuando λ_k se aproxima a cero?*

Presión arterial: diagnóstico mediante valores propios

En el ejemplo de presión arterial, el índice de condición máximo es:

$$IC_{\max} \approx 201.496.$$

Este resultado sugiere que existe una combinación de regresores cercana a una dependencia lineal exacta.

Los VIF permiten examinar la inflación de la varianza de cada coeficiente, mientras que el índice de condición proporciona información sobre la dependencia lineal del conjunto de regresores.

¿Serían suficientes estos resultados para decidir eliminar alguna variable?

¿Qué hacemos con la multicolinealidad?

¿Siempre debemos corregirla?

Bajo los supuestos clásicos, la multicolinealidad imperfecta:

- No produce sesgo en los estimadores MCO.
- No elimina su propiedad MELI.
- No invalida, por sí sola, las pruebas de hipótesis.
- Puede dificultar la estimación precisa de ciertos coeficientes.

Por tanto, no siempre es necesario modificar el modelo. *La decisión depende de qué parámetros queremos estimar y con qué precisión necesitamos conocerlos*.

¿Qué ocurre si eliminamos un regresor? (1/3)

Ejercicio*

Supongamos que el modelo verdadero es:

$$y_i = \beta_1 + \beta_2 x_{2i} + \beta_3 x_{3i} + u_i;$$

Para reducir la multicolinealidad, estimamos un modelo que excluye a x_3:

$$y_i = \widetilde{b}_1 + \widetilde{b}_2 x_{2i} + \widetilde{e}_i.$$

¿Qué ocurre si eliminamos un regresor? (2/3)

Demuestra que, cuando excluimos a x_3:

$$E(\widetilde{b}_2) = \beta_2 + \beta_3 \frac{S_{23}}{S_{22}}.$$

¿En qué condiciones $\widetilde{b}_2$ es insesgado para β_2?

¿Qué ocurre si eliminamos un regresor? (3/3)

Bajo los supuestos clásicos del modelo verdadero, demuestra que:

$$\text{Var}(\tilde{b}_2) = \frac{\sigma^2}{S_{22}}.$$

Compara este resultado con:

$$\text{Var}(b_2) = \frac{\sigma^2}{S_{22}(1 - r_{23}^2)}.$$

¿Qué sucede con la varianza cuando eliminamos x_3?

Entonces, *¿podemos justificar la eliminación de un regresor únicamente porque reduce la varianza del estimador?*

¿Cómo debemos actuar?

La decisión depende del objetivo del análisis.

- Mantener el modelo si la precisión obtenida es suficiente para responder nuestra pregunta.
- Obtener datos que aporten mayor variación independiente de los regresores de interés.
- Examinar si determinadas combinaciones de coeficientes permiten responder la pregunta.
- Modificar la especificación cuando exista una justificación económica, no solamente estadística.

> **Eliminar regresores por tener un VIF elevado no garantiza una mejor estimación.**

Resumen

¿Qué hemos aprendido?

Cuando los regresores contienen información muy parecida:

- Si existe *multicolinealidad perfecta*, los coeficientes no están determinados de manera única.
- Si la *multicolinealidad es imperfecta*, MCO permite estimarlos, pero su precisión puede verse afectada.
- Algunas combinaciones de coeficientes pueden seguir estimándose con precisión.
- El diagnóstico debe orientar nuestras decisiones, no sustituir el razonamiento económico.

> **La pregunta no es solamente si podemos estimar un modelo, sino qué conclusiones permiten sostener los datos.**

¿Qué sigue?

Hasta ahora hemos estudiado cómo la información compartida entre regresores puede dificultar la estimación de sus efectos individuales. En los siguientes capítulos aprenderemos a construir especificaciones más flexibles, incorporando nuevas formas de representar las relaciones económicas.

> **Cada decisión sobre la especificación del modelo también es una decisión sobre la evidencia que podemos construir.**