

Econometría I

Tarea 1: El modelo de regresión lineal simple

Alejandro Mosiño - Universidad de Guanajuato

Indicaciones. Resuelve cuidadosamente los cuatro ejercicios antes de responder el cuestionario correspondiente en Campus Digital. El cuestionario evalúa las ideas, procedimientos y resultados desarrollados en esta tarea, aunque sus preguntas no necesariamente reproducen los mismos ejercicios o datos. Trabajar y comprender previamente los ejercicios es la mejor preparación para resolverlo.

Ejercicio 1

Considera el modelo de regresión lineal simple

$$y_i = \beta_1 + \beta_2 x_i + u_i.$$

Para una muestra de $n = 20$ observaciones se conoce la siguiente información:

$$\bar{x} = 4, \quad \bar{y} = 11,$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = 50,$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = 75, \quad S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = 150.$$

- a) Utiliza únicamente la información proporcionada para obtener los estimadores de MCO b_1 y b_2 , y escribe la recta estimada. Determina después el valor ajustado correspondiente a $x = \bar{x}$ y explica por qué el resultado no es una coincidencia de los datos de este ejercicio.

- b) A partir de

$$\hat{y}_i - \bar{y} = b_2(x_i - \bar{x}),$$

muestra que

$$ESS = b_2^2 S_{xx}.$$

Utiliza esta identidad y la descomposición $TSS = ESS + RSS$ para calcular ESS , RSS y R^2 , sin reconstruir las observaciones individuales.

- c) Considera una segunda muestra para la cual

$$S_{xx} = 200, \quad S_{xy} = 150, \quad S_{yy} = 150.$$

Calcula b_2 y R^2 . Compara estos resultados con los obtenidos en los incisos anteriores y explica por qué dos regresiones pueden tener pendientes diferentes y el mismo R^2 . ¿Qué mide cada uno de estos objetos?

- d) A partir de $ESS = b_2^2 S_{xx}$ y $b_2 = S_{xy}/S_{xx}$, muestra que, en una regresión lineal simple con constante,

$$R^2 = r_{xy}^2, \quad r_{xy} = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}.$$

Calcula r_{xy} para la muestra original. Si únicamente conocieras el valor de R^2 , ¿podrías determinar el signo de r_{xy} ? Explica qué información adicional permite determinarlo.

- e) Define $x_i^* = x_i - \bar{x}$ y considera la regresión de y_i sobre x_i^* , con constante:

$$y_i = b_1^* + b_2^* x_i^* + e_i^*.$$

Sin volver a estimar la regresión desde cero, determina b_1^* y b_2^* . Muestra que los valores ajustados de ambas regresiones son iguales para cada observación y deduce qué ocurre con los residuos, RSS y R^2 .

- f) Después de centrar x , el intercepto cambia, pero la pendiente y el ajuste permanecen iguales. Explica en qué sentido cambió la ecuación estimada y en qué sentido sigue representando la misma recta.

¿Qué has aprendido? Una regresión lineal simple puede reconstruirse a partir de unas pocas cantidades muestrales. La pendiente, la bondad del ajuste y la correlación describen aspectos relacionados, pero distintos, de los datos. Cambiar el origen desde el cual medimos x modifica el intercepto, pero no la pendiente ni el ajuste de la regresión.

Ejercicio 2

Sea

$$\hat{y}_i = b_1 + b_2 x_i$$

la recta estimada por MCO, con residuos $e_i = y_i - b_1 - b_2 x_i$. Considera cualquier otra recta

$$\tilde{y}_i = c_1 + c_2 x_i$$

y define

$$d_1 = c_1 - b_1, \quad d_2 = c_2 - b_2.$$

a) Muestra que el residuo producido por la recta alternativa puede escribirse como

$$y_i - c_1 - c_2 x_i = e_i - d_1 - d_2 x_i.$$

Desarrolla $RSS(c_1, c_2) = \sum_i (e_i - d_1 - d_2 x_i)^2$ y utiliza las ecuaciones normales

$$\sum_i e_i = 0, \quad \sum_i x_i e_i = 0$$

para demostrar que

$$RSS(c_1, c_2) - RSS(b_1, b_2) = \sum_{i=1}^n (d_1 + d_2 x_i)^2 \geq 0.$$

Explica por qué este resultado demuestra que la recta de MCO minimiza globalmente el RSS , y no solamente que satisface condiciones de primer orden.

b) ¿Cuándo puede cumplirse

$$RSS(c_1, c_2) = RSS(b_1, b_2)?$$

Muestra que, si $S_{xx} > 0$, la igualdad requiere $d_1 = d_2 = 0$. Explica por qué la variación de x es necesaria para identificar una pendiente única y qué ocurriría si todos los x_i fueran iguales.

c) Escribe cualquier recta alternativa en la forma centrada

$$\tilde{y}_i = \hat{y}_i + a + h(x_i - \bar{x}),$$

donde a modifica el valor ajustado en $x = \bar{x}$ y h modifica la pendiente. Demuestra que

$$RSS(\tilde{y}) - RSS(\hat{y}) = na^2 + h^2 S_{xx}.$$

Interpreta por qué el centrado permite separar exactamente el costo de modificar el nivel y el costo de modificar la pendiente.

d) Considera una recta alternativa que conserva el punto $(\bar{x}, \bar{y})$, pero cuya pendiente es $b_2 + h$. ¿Cuánto aumenta su RSS ? Compara dos muestras con el mismo valor de h , pero diferentes valores de S_{xx} , y explica el papel que desempeña la dispersión de x .

e) En clase se construyó un estimador de la pendiente utilizando únicamente dos observaciones y se mostró que, bajo los supuestos correspondientes, puede ser insesgado. ¿Contradice esto la propiedad de minimización que acabas de demostrar? Distingue con precisión las siguientes afirmaciones:

- MCO minimiza el RSS en la muestra
- un estimador es insesgado,
- MCO es MELI bajo los supuestos de Gauss–Markov.

¿Qué has aprendido? Las condiciones que satisfacen los residuos de MCO permiten demostrar que ninguna otra recta puede producir una suma de residuos al cuadrado menor. La variación de x permite identificar una pendiente única. La minimización del RSS , la insesgadez y la eficiencia son propiedades diferentes que responden preguntas diferentes.

Ejercicio 3

Considera nuevamente el modelo

$$y_i = \beta_1 + \beta_2 x_i + u_i,$$

donde los x_i son deterministas y

$$\mathbb{E}(u_i) = 0, \quad \mathbb{V}ar(u_i) = \sigma^2, \quad \mathbb{C}ov(u_i, u_j) = 0 \quad (i \neq j).$$

Puedes utilizar los resultados demostrados en clase:

$$\mathbb{E}(b_2) = \beta_2, \quad \mathbb{V}ar(b_2) = \frac{\sigma^2}{S_{xx}}, \quad S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2.$$

a) Considera los dos diseños siguientes, ambos con $n = 5$:

$$x^{(A)} = (4, 5, 6, 7, 8), \quad x^{(B)} = (0, 3, 6, 9, 12).$$

Supón que σ^2 es la misma en ambos casos. Calcula S_{xx} y $\mathbb{V}ar(b_2)$ para cada diseño. ¿En cuál de ellos se estima β_2 con mayor precisión y por qué?

b) ¿Una muestra con más observaciones produce necesariamente una varianza menor para b_2 ? Responde utilizando la expresión de $\mathbb{V}ar(b_2)$ y explica qué característica del diseño, además del número de observaciones, determina la precisión de la pendiente.

c) Utiliza

$$b_1 = \bar{y} - b_2 \bar{x} = \beta_1 + \bar{u} - (b_2 - \beta_2) \bar{x}$$

para demostrar que

$$\mathbb{V}ar(b_1) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}} \right) = \sigma^2 \left[\frac{\sum_i x_i^2}{n S_{xx}} \right]$$

y

$$\mathbb{C}ov(b_1, b_2) = -\frac{\bar{x} \sigma^2}{S_{xx}}.$$

Para simplificar el desarrollo, puedes utilizar

$$\mathbb{V}ar(\bar{u}) = \frac{\sigma^2}{n}, \quad \mathbb{C}ov(\bar{u}, b_2 - \beta_2) = 0,$$

y

$$\sum_i x_i^2 = S_{xx} + n \bar{x}^2.$$

d) Define nuevamente $x_i^* = x_i - \bar{x}$. Utiliza los resultados del Ejercicio 1, sin repetir la derivación de la invariancia del ajuste, para obtener

$$\mathbb{V}ar(b_1)^*, \quad \mathbb{V}ar(b_2)^*, \quad \mathbb{C}ov(b_1^*, b_2^*).$$

Interpreta por qué centrar x cambia la relación entre los estimadores del intercepto y la pendiente, aunque no cambie la recta ajustada.

e) Supón ahora que

$$u_i \sim^{iid} \mathcal{N}(0, \sigma^2).$$

Explica por qué b_1 y b_2 son variables normales y escribe sus distribuciones utilizando las esperanzas y varianzas anteriores. En la regresión con x_i^* , ¿qué conclusión adicional permite obtener la combinación de normalidad conjunta y $\text{Cov}(b_1^*, b_2^*) = 0$?

f) Si se elimina el supuesto de normalidad, pero se conservan los supuestos sobre la media, la varianza y la covarianza de los errores, indica cuáles de los resultados anteriores permanecen válidos y cuál deja de estar garantizado. Explica por qué incorrelación e independencia no son equivalentes en general.

¿Qué has aprendido? La precisión con la que estimamos una pendiente no depende únicamente del número de observaciones, sino también de la variación de x . Centrar x no cambia la pendiente ni el ajuste, pero modifica la relación entre los estimadores del intercepto y la pendiente. La normalidad no es necesaria para la insesgadez; su papel es permitirnos caracterizar exactamente la distribución de los estimadores y, en este caso, convertir incorrelación en independencia.

Ejercicio 4

Considera el modelo

$$y_i = \beta_1 + \beta_2 x_i + u_i,$$

donde los x_i son deterministas y

$$\mathbb{E}(u_i) = 0, \quad \mathbb{V}ar(u_i) = \sigma^2, \quad \mathbb{C}ov(u_i, u_j) = 0 \quad (i \neq j).$$

Los residuos de MCO y su suma de cuadrados son

$$e_i = y_i - b_1 - b_2 x_i, \quad RSS = \sum_{i=1}^n e_i^2.$$

a) Si los verdaderos errores u_i fueran observables, podríamos considerar $n^{-1} \sum_i u_i^2$. Muestra que

$$\mathbb{E} \left(\frac{1}{n} \sum_i u_i^2 \right) = \sigma^2.$$

Explica por qué este resultado no justifica sustituir directamente los errores por los residuos y utilizar RSS/n .

b) A partir de las definiciones de e_i , b_1 y b_2 , muestra que

$$e_i = (u_i - \bar{u}) - (b_2 - \beta_2)(x_i - \bar{x}).$$

¿Qué dos ajustes realizados con los datos distinguen a e_i de u_i ?

c) Utiliza la identidad

$$\sum_i (u_i - \bar{u})^2 = \sum_i u_i^2 - n\bar{u}^2$$

y los resultados

$$\mathbb{E} \left(\sum_i u_i^2 \right) = n\sigma^2, \quad \mathbb{V}ar(\bar{u}) = \frac{\sigma^2}{n}$$

para demostrar que

$$\mathbb{E} \left[\sum_i (u_i - \bar{u})^2 \right] = (n-1)\sigma^2.$$

d) Define $a = b_2 - \beta_2$. Eleva al cuadrado y suma la expresión obtenida en el inciso b). Utiliza

$$\sum_i (x_i - \bar{x})(u_i - \bar{u}) = \sum_i (x_i - \bar{x})u_i = aS_{xx}$$

para demostrar que

$$RSS = \sum_i (u_i - \bar{u})^2 - a^2 S_{xx}.$$

e) Toma esperanza en la expresión anterior. Utiliza la insesgadez de b_2 y

$$\text{Var}(b_2) = \frac{\sigma^2}{S_{xx}}$$

para demostrar que

$$\mathbb{E}(RSS) = (n-2)\sigma^2.$$

Explica cómo aparecen, paso a paso, los dos grados de libertad utilizados al estimar el intercepto y la pendiente.

f) Define

$$s^2 = \frac{RSS}{n-2}.$$

Demuestra que s^2 es un estimador insesgado de σ^2 . Considera después el estimador

$$\tilde{\sigma}^2 = \frac{RSS}{n}$$

y obtén su esperanza y su sesgo. Calcula qué fracción de σ^2 estima en promedio cuando $n = 10$ y cuando $n = 100$. ¿El hecho de que el sesgo relativo disminuya al crecer n convierte a RSS/n en un estimador insesgado para una muestra finita?

¿Qué has aprendido? Los residuos no son los errores poblacionales: se obtienen después de utilizar los datos para estimar el intercepto y la pendiente. Por ello, RSS/n subestima sistemáticamente σ^2 . La división entre $n-2$ no es una regla arbitraria: corrige la variación utilizada al estimar los dos parámetros de la recta.